INCERTEZA CAP 13

Parcialmente adaptado de http://aima.eecs.berkeley.edu

Resumo

- Incerteza
- Probabilidade
- Sintaxe e Semântica
- Inferência
- Independência e Regra de Bayes

Incerteza

- Seja a ação A_t = sair para o aeroporto t minutos antes do vôo.
- Será que A_t me permite chegar ao aeroporto a tempo?
- Problemas:
 - Estados parcialmente observáveis (condições da estrada, outros condutores, etc.)
 - Sensores com ruído (notícias de trânsito)
 - Incerteza quanto aos efeitos das ações (pneu furado, etc.)
 - Grande complexidade da modelação e previsão do trânsito
- Logo, numa aproximação puramente lógica, das duas uma:
 - Arrisca-se a ser falsa a proposição "A₂₅ permite-me chegar ao aeroporto a tempo", ou
 - 2. Leva a conclusões que são demasiado fracas para a tomada de decisões: "A₂₅ permitir-me-a chegar a tempo, se não houver qualquer acidente na ponte, e se não chover, e se nenhum pneu furar, etc., etc."
- A₁₄₄₀ pode garantir-me com alguma certeza que chegarei a tempo, mas terei que pernoitar no aeroporto

Métodos para lidar com incerteza

- Lógicas por omissão ou não-monótonas:
 - Assumir que o meu carro não tem um pneu vazio
 - Assumir que A₂₅ funciona a não ser que seja contradito pela evidência
- Problemas: Quais as assunções razoáveis? Como lidar com a contradição?
- Regras com factores inventados:
 - A₂₅ →_{0.3} chegar a tempo
 - Sprinkler $\mapsto_{0.99}$ WetGrass
 - WetGrass →_{0.7} Rain
- Problemas: como se combinam os factores, e.g., Sprinkler provoca Rain??
- Probabilidade
 - Modela o grau de crença de um agente
 - Dada a evidência existente,
 - A₅ permitir-me-á chegar a tempo com probabilidade 0.04

Probabilidade

- Asserções probabilísticas sumariam efeitos de
 - preguiça: incapacidade de enumerar exceções, qualificações, etc.
 - ignorância: desconhecimento de teoria sobre o domínio, factos relevantes, condições iniciais, etc.
- Probabilidades subjetivas ou Bayesianas:
 - Probabilidades relacionam proposições com o estado de conhecimento do agente,
 - e.g., P(A₂₅|não há notícias de acidentes) = 0,06
- Não são proposições sobre o mundo o mundo real não é incerto.
- São proposições sobre o estado de conhecimento/crença do agente sobre o mundo.
 - As probabilidades das proposições alteram-se com nova evidência:
 - e.g., P(A₂₅|não há notícias de acidentes, 5 a.m.) = 0,15
- Compromisso ontológico da probabilidade é igual ao da lógica. O compromisso epistemológico é que é diferente: na lógica é verdadeiro/falso enquanto que na probabilidade é numérico.

Decidindo sob condições de incerteza

- Suponha o seguinte conjunto de crenças:
 - $P(A_{25} \text{ permite-me chegar a tempo} | ...) = 0.04$
 - $P(A_{90} \text{ permite-me chegar a tempo} | ...) = 0.70$
 - $P(A_{120} \text{ permite-me chegar a tempo} | ...) = 0.95$
 - $P(A_{1440} \text{ permite-me chegar a tempo} | \dots) = 0.9999$
- Que ação escolher?
 - Depende de minhas preferências sobre perder o vôo vs. tempo de espera no aeroporto vs. gastronimia aeroportuária, etc.
 - Teoria da utilidade é utilizada para representar e inferir preferências (todo estado tem um grau de utilidade)
 - Teoria da Decisão = teoria da probabilidade + teoria da utilidade

Fundamentos de Probabilidades

- Comece-se com um conjunto Ω, o espaço amostra
- ω∈Ω é um ponto amostra/mundo possível/acontecimento atómico
- Um acontecimento atómico é uma especificação completa do estado do mundo acerca do qual o agente tem incerteza. Os acontecimentos atómicos são mutuamente exclusivos e exaustivos (e.g. 6 lançamentos de um dado).
- Um espaço de probabilidade ou modelo de probabilidade é um espaço amostra com uma atribuição P(ω) para todo o ω∈Ω tal que
 - $0 \le P(\omega) \le 1$
 - $\sum_{\omega} P(\omega) = 1$
- e.g., P(1)=P(2)=P(3)=P(4)=P(5)=P(6)=1/6.
- Um acontecimento (evento) A é qualquer subconjunto de Ω
 - $P(A) = \sum_{\{\omega \in A\}} P(\omega)$
 - E.g., P(lançamento do dado < 4) = 1/6 + 1/6 + 1/6 = 1/2

Variáveis Aleatórias

- Proposições descrevendo acontecimentos (conjuntos de pontos de amostra) usam uma notação que combina a lógica proposicional e a notação de satisfação de restrições.
- As variáveis em teoria da probabilidade são designadas por variáveis aleatórias.
- Cada variável aleatória tem um domínio.
 - E.g. o domínio de Weather é {sunny, rainy, cloudy, snow }.
- Uma variável aleatória booleana tem o domínio {verdadeiro, falso}.
- Nas aplicações de IA, os pontos amostra são normalmente definidos pelos valores de um conjunto de variáveis aleatórias, i.e., o espaço amostra é o produto Cartesiano dos domínios das variáveis.
- Sejam as v.as. Dado ∈ {1,2} e Pintas ∈ {1,2,3,4,5,6}. Os pontos amostra são (atenção isto não é lançamento simultâneo dos dados, mas sim o lançamento de um dos dados!):
 - < 1, 1 > < 1, 2 > < 1, 3 > < 1, 4 > < 1, 5 > < 1, 6 >
 - < 2, 1 > < 2, 2 > < 2, 3 > < 2, 4 > < 2, 5 > < 2, 6 >

Sintaxe para as proposições

- O elemento básico é a variável aleatória cujos valores devem ser exaustivos e mutuamente exclusivos.
- Variáveis aleatórias proposicionais ou Booleanas
 - Cavity = true ou Cavity = false (tenho/não tenho uma cárie?)
 - Estas proposições podem ser representadas por cavity ou ¬cavity.
- Variáveis aleatórias discretas (finitas ou infinitas)
 - V.a. Weather toma valores em < sunny, rainy, cloudy, snow >
 - Weather = rainy é uma proposição
 - Quando não há ambiguidade, podemos usar o valor da variável aleatória (rainy) em vez da proposição (Weather = rainy)
- Variáveis aleatórias continuas (limitadas ou ilimitadas)
 - e.g., Temp=21.6; também permite, e.g. Temp < 22.0.
- Podemos combinar proposições (usando os conectivos da lógica proposicional) para obter outras proposições, por exemplo, Cavity = false V Weather = sunny.
- Entende-se uma proposição como sendo o acontecimento (conjunto de pontos amostra) onde a proposição é verdadeira

Probabilidade incondicional ou à priori


- Probabilidades à priori ou probabilidades incondicionais de proposições
 - e.g., P(Cavity = true) = 0.1 e P(Weather = sunny) = 0.72
 - correspondem à crença do agente antes da chegada de (nova) evidência
- Distribuição de probabilidade dá valores a todas as atribuições possíveis:
 - P(Weather) = <0.72; 0.1; 0.08; 0.1> (normalizado, i.e., soma 1)
 - Bold (em P) significa um vector, assumindo ordenação fixa do domínio da variável.
- Distribuição de probabilidade conjunta para um conjunto de v.a.s dá-nos a probabilidade de cada acontecimento atómico nessas v.a.s. (i.e., em cada ponto amostra)
 - **P**(Weather, Cavity) = uma matriz de 4× 2 valores:

Weather=	sunny	rain	cloudy	snow
Cavity=true	0.144	0.02	0.016	0.02
Cavity=false	0.576	0.08	0.064	0.08

 Toda a questão num domínio pode ser respondida pela distribuição conjunta porque todo o acontecimento é uma soma de pontos amostra

Probabilidade para variáveis contínuas

- Exprime distribuição como função parametrizada de valor:
- P(X=x) = U/18,26/(x) = densidade uniforme entre 18 e 26




• Em que P é uma densidade de probabilidade; integrando em todo o domínio dá 1. P(X=20.5)=0.125 realmente signica

$$\lim_{dx\to 0} P(20.5 \le X \le 20.5 + dx)/dx = 0.125$$

Função de densidade Gaussiana ou Normal

$$P(x) = \frac{1}{\sqrt{2\pi\sigma}} e^{-(x-\mu)^2/2\sigma^2}$$



Probabilidade condicional ou à posteriori

- Probabilidades à posteriori ou condicionais
 - e.g., P(cavity | toothache) = 0.8
 - i.e., toothache é tudo o que sei
- Notação para distribuições condicionais:
 - P(X | Y) = conjunto de valores de P(X=x_i | Y=y_i) para cada i,j possível
- Se soubermos mais, e.g., cavity também é dado, então temos
 - P(cavity | toothache, cavity) = 1
- Nota: a crença menos específica continua válida após mais evidência chegar, mas nem sempre é útil
- Nova evidência pode ser irrelevante, permitindo simplificação, e.g.,
 - P(cavity | toothache, AcadémicaGanha) = P(cavity | toothache) = 0.8
- Esta forma de inferência, sancionada pelo conhecimento do domínio, é crucial


Probabilidade Condicional

- Probabilidade condicional pode ser definida em termos das probabilidades incondicionais:
 - $P(a \mid b) = P(a \land b) / P(b)$, se $P(b) \neq 0$
- Regra do produto é uma formulação alternativa:
 - $P(a \land b) = P(a \mid b) P(b) = P(b \mid a) P(a)$
- Pode ser generalizado para distribuições totais:
 - $\mathbf{P}(Weather, Cavity) = \mathbf{P}(Weather \mid Cavity) \mathbf{P}(Cavity)$
 - (vista como um conjunto de 4 × 2 equações, não multiplicação de matrizes)
- Regra da cadeia é obtida a partir de aplicações sucessivaas da regra do produto:

$$\mathbf{P}(X_{1}, ..., X_{n}) = \mathbf{P}(X_{1}, ..., X_{n-1}) \mathbf{P}(X_{n} | X_{1}, ..., X_{n-1})
= \mathbf{P}(X_{1}, ..., X_{n-2}) \mathbf{P}(X_{n-1} | X_{1}, ..., X_{n-2}) \mathbf{P}(X_{n} | X_{1}, ..., X_{n-1})
= ...
= \prod_{i=1}^{n} \mathbf{P}(X_{i} | X_{1}, ..., X_{i-1})$$

Porquê usar probabilidades?

- Axiomas da probabilidade. Para quaisquer proposições A e B:
 - $0 \le P(A) \le 1$
 - P(true) = 1 e P(false) = 0
 - $P(A \lor B) = P(A) + P(B) P(A \land B)$



 de Finetti (1931): um agente que aposte com probabilidades que violem os axiomas da teoria das probabilidades pode ser forçado a apostar de maneira a perder dinheiro, independentemente do resultado.

Argumento de de Finetti

- Preâmbulo: se um agente tem um grau de crença numa proposição, deveria ser capaz de indicar a chance (odds) na qual lhe seria indiferente apostar a favor ou contra essa proposição.
- Por exemplo, se um agente 1 tiver um grau de crença num evento a de 0.4, um agente 2 pode escolher se pretende apostar a favor ou contra a, com valores consistentes com o grau de crença.
- O agente 2 poderia aceitar a aposta de 1 em a, oferecendo e.g. 6€ contra os 4€ do agente 1, ou apostar a favor de a, oferecendo 4€ em troca de 6€ do agente 1.
- Para o agente 1, as duas apostas seriam igualmente aceitáveis i.e. para o agente 1 é indiferente apostar a favor ou contra a com 4 para 6, ou 6 para 4, respectivamente.

Argumento de de Finetti

- Vamos agora assumir que o agente 1 tem crenças que violam os axiomas da probabilidade.
- Por exemplo, vamos considerar que o agente 1 tem uma crença em a de 0.4, uma crença em b de 0.3, e uma crença em a ∨ b de 0.8 (que viola o axioma P(A ∨ B) = P(A) + P(B) P(A ∧ B)).
- De acordo com de Finetti, será possível a um agente 2 construir uma aposta que o agente 1 aceitará (mostraremos o caso em que é indiferente), e que o fará perder dinheiro, independentemente do resultado.
- Neste caso, a aposta é composta por 3 apostas individuais, cada uma das quais é indiferente para o agente 1.

Age	nte 1	Ageı	nte 2	Resultado e payoff para o Agente 1			gente 1
Prop.	Crença	Aposta	Stakes	a,b	a,¬b	¬a,b	¬a,¬b
a	0.4						
b	0.3						
a∨b	0.8						

Comece-se com a distribuição conjunta:

	toothache		$\neg toothache$	
	catch ¬catch		catch	$\neg catch$
cavity	.108	.012	.072	.008
¬cavity	.016	.064	.144	.576

 Para qualquer proposição φ, somar os acontecimentos atómicos onde φ é verdade:

$$P(\varphi) = \sum_{\omega : \omega = \varphi} P(\omega)$$

Calcular P(toothache) (probabilidade marginal de toothache)?

Comece-se com a distribuição conjunta:

	toothache		$\neg toothache$	
	catch ¬catch		catch	$\neg catch$
cavity	.108	.012	.072	.008
¬cavity	.016	.064	.144	.576

 Para qualquer proposição φ, somar os acontecimentos atómicos onde φ é verdade:

$$P(\varphi) = \sum_{\omega : \omega = \varphi} P(\omega)$$

A probabilidade marginal de toothache é:

$$P(toothache) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$

Calcular P(cavity V toothache)?

Comece-se com a distribuição conjunta:

	toothache		$\neg toothache$	
	catch ¬catch		catch	$\neg catch$
cavity	.108	.012	.072	.008
¬cavity	.016	.064	.144	.576

 Para qualquer proposição φ, somar os acontecimentos atómicos onde φ é verdade:

$$P(\varphi) = \sum_{\omega:\omega \models \varphi} P(\omega)$$

 $P(cavity \ \ \ toothache) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.2$

Calcular P(¬cavity | toothache)?

Comece-se com a distribuição conjunta:

	toothache		$\neg toothache$	
	catch	$\neg catch$	catch	$\neg catch$
cavity	.108	.012	.072	.008
¬cavity	.016	.064	.144	.576

Podemos calcular probabilidades condicionais:

$$P(\varphi) = \sum_{\omega:\omega \vDash \varphi} P(\omega)$$

$$P(\neg cavity \mid toothache) = P(\neg cavity \land toothache) / P(toothache)$$

$$= (0.016 + 0.064) / (0.108 + 0.012 + 0.016 + 0.064)$$

$$= 0.4$$

Comece-se com a distribuição conjunta:

	toothache		$\neg toothache$	
	catch ¬catch		catch	$\neg catch$
cavity	.108	.012	.072	.008
¬cavity	.016	.064	.144	.576

• Denominador pode ser visto como constante de normalização α • P(Cavity | toothache) = α P(Cavity, toothache)

=
$$\alpha [\mathbf{P}(Cavity, toothache, catch) + \mathbf{P}(Cavity, toothache, \neg catch)]$$

$$= \alpha [<0.108, 0.016> + <0.012, 0.064>]$$

$$= \alpha < 0.12, 0.08 > = < 0.6, 0.4 >$$

 Ideia geral: calcular distribuição na variável interrogada, fixando as variaveis evidência e somando variáveis ocultas

Marginalização (método genérico)

- Para quaisquer conjuntos de variáveis Y, Z, temos:
- $P(Y) = \sum_{z \in \mathbb{Z}} P(Y,z)$
- Ou através da condicionalização
- $P(Y) = \sum_{z \in \mathbb{Z}} P(Y|z) P(z)$

Inferência probabilistica


- Habitualmente, estamos interessados na
 - distribuição conjunta à posteriori das variáveis interrogadas Y
 - dados valores específicos e para as variáveis evidência E
- Sejam as variáveis ocultas dadas por H = X-Y-E
- Logo, o somatório das entradas conjuntas é obtida somando as variáveis ocultas:

$$P(Y|E=e) = \alpha P(Y,E=e) = \alpha \sum_{h} P(Y,E=e,H=h)$$

- Os termos no somatório são as entradas da distribuição conjunta porque Y, E, e H é o conjunto de todas as variáveis aleatórias
- Problemas óbvios:
 - 1) Complexidade temporal pior caso O(dn) em que d é a maior aridade
 - 2) Complexidade espacial O(dⁿ) para armazenar a distribuição conjunta
 - 3) Como encontrar os valores para O(dⁿ) entradas???

Independência

- A e B são independentes sse
- P(A|B) = P(A) ou P(B|A) = P(B) ou P(A,B) = P(A)P(B)



- P(Toothache, Catch, Cavity, Weather)
 - = P(Toothache, Catch, Cavity)P(Weather)
- 32 entradas reduzidas a 12, para n moedas, 2ⁿ → n
- Independência absoluta é poderosa, mas rara
- Medicina Dentária é uma área do conhecimento com centenas de variáveis, nenhumas delas independentes. O que fazer?

Independência Condicional

- P(Toothache, Cavity, Catch) tem $2^3 1 = 7$ entradas independentes
- Se eu tenho uma cárie, a probabilidade que a sonda fique presa (catch) é independente do facto de eu ter dor de dentes:
 - 1. $P(catch \mid toothache, cavity) = P(catch \mid cavity)$
- A mesma relação de independência verifica-se se eu não tiver uma cárie:
 - 2. $P(catch \mid toothache, \neg cavity) = P(catch \mid \neg cavity)$
- Catch é condicionalmente independente de Toothache dado Cavity:
 - $P(Catch \mid Toothache, Cavity) = P(Catch \mid Cavity)$
- Afirmações Equivalentes:
 - $\mathbf{P}(Toothache \mid Catch, Cavity) = \mathbf{P}(Toothache \mid Cavity)$
 - $\mathbf{P}(Toothache, Catch \mid Cavity) = \mathbf{P}(Toothache \mid Cavity) \mathbf{P}(Catch \mid Cavity)$

Independência Condicional (numericamente)

- Sejam X, Y e Z três conjuntos de variáveis aleatórias.
- Diz-se que X é condicionalmente independente de Y dado Z, quando para todo o acontecimento Z=z com P(Z=z)>0 e qualquer par de acontecimentos X=x e Y=y se tem:

$$P(X=x, Y=y, Z=z) = P(X=x, Z=z) P(Y=y, Z=z) / P(Z=z)$$

Independência Condicional

 Escrevendo a distribuição conjunta utilizando a regra da cadeia:

```
P(Toothache, Catch, Cavity)
```

- = **P**(Toothache | Catch, Cavity) **P**(Catch, Cavity)
- = **P**(Toothache | Catch, Cavity) **P**(Catch | Cavity) **P**(Cavity)
- $= \mathbf{P}(Toothache \mid Cavity) \ \mathbf{P}(Catch \mid Cavity) \ \mathbf{P}(Cavity)$
- i.e. 2+2+1=5 valores independentes (equações 1 e 2 removem 2).
- Na maioria das situações, a utilização da independência condicional reduz o tamanho da representação da distribuição conjunta de exponencial em n para linear em n.
- A independência condicional é a mais básica e robusta forma de conhecimento acerca de ambientes incertos.

Desafio

- Considere-se a seguinte situação real:
 - 1% das mulheres com quarenta anos que efetuam regularmente rastreio têm cancro da mama.
 - Cerca de 80% dessas mulheres obterão uma mamografia positiva.
 - 9.6% das mulheres sem cancro da mama também têm mamografia positiva.
- Uma mulher neste grupo etário teve uma mamografia positiva no rastreio regular.

Qual é a probabilidade de ela ter cancro da mama?

(Só cerca de 15% dos médicos se aproxima da resposta correta...)

Regra de Bayes

• Da regra do produto $P(a \land b) = P(a|b)P(b) = P(b|a) P(a)$ obtemos a Regra de Bayes:

 $P(a \mid b) = \frac{P(b \mid a)P(a)}{P(b)}$

Ou na forma da distribuição conjunta:

$$\mathbf{P}(Y \mid X) = \frac{\mathbf{P}(X \mid Y)\mathbf{P}(Y)}{\mathbf{P}(X)} = \alpha \mathbf{P}(X \mid Y)\mathbf{P}(Y)$$

Variante condicionalizada na evidência e fornecida

$$\mathbf{P}(Y \mid X, \mathbf{e}) = \frac{\mathbf{P}(X \mid Y, \mathbf{e})\mathbf{P}(Y \mid \mathbf{e})}{\mathbf{P}(X \mid \mathbf{e})} = \alpha \mathbf{P}(X \mid Y, \mathbf{e})\mathbf{P}(Y \mid \mathbf{e})$$

Útil para obter a probabilidade do diagnóstico dada a probabilidade causal

$$P(Causa \mid Efeito) = \frac{P(Efeito \mid Causa)P(Causa)}{P(Efeito)}$$

Regra de Bayes: exemplo

- Considere o seguinte conhecimento médico:
 - Meningite provoca rigidez do pescoço em 70% dos casos
 - A probabilidade à priori de um paciente ter meningite é de 1 em 50000.
 - A probabilidade à priori de um paciente ter o pescoço rígido é 0.01.
- Seja M meningite, R pescoço rígido:
- $P(m|r)=P(r|m)P(m)/P(r)=.7*.00002/.01=.0014 \approx (1 \text{ em } 7000)$
- Nota: a probabilidade à posteriori de meningite é ainda muito pequena!
- Já é capaz de responder ao desafio anterior?

Desafio

- Considere-se a seguinte situação real:
 - 1% das mulheres com quarenta anos que efetuam regularmente rastreio têm cancro da mama. Cerca de 80% dessas mulheres obterão uma mamografia positiva. 9.6% das mulheres sem cancro da mama também têm mamografia positiva.
- Uma mulher neste grupo etário teve uma mamografia positiva no rastreio regular.

Qual é a probabilidade de ela ter cancro da mama?

- (Só cerca de 15% dos médicos se aproxima da resposta correta...)
- Seja C="tem cancro da mama" e M="teve uma mamografia positiva"
- Problema: P(c)=0.01; P(m|c)=0.8; $P(m|\neg c)=0.096$. P(c|m)=?
- Regra de Bayes: P(c|m)=P(m|c)P(c)/P(m)
- Marginalização: $P(m)=P(m|c)P(c)+P(m|\neg c)P(\neg c)=.8*.01+.096*.99=.10304$
- Resolvendo: $P(c|m)=P(m|c)P(c)/P(m)=.8*.01/.10304=.0776 \approx 7.8\%$

Regra de Bayes e independência condicional


- $\mathbf{P}(Cavity|toothache \land catch)$
 - = $\alpha P(toothache \land catch | Cavity) P(Cavity)$
 - = $\alpha P(toothache|Cavity) P(catch|Cavity) P(Cavity)$
- Isto é um exemplo do modelo naive de Bayes (uma causa única influencia um número de efeitos, todos independentes dada a causa).
- A distribuição conjunta total é dada por:

$$\mathbf{P}(Cause, Effect_1, ..., Effect_n) = \mathbf{P}(Cause) \prod_i \mathbf{P}(Effect_i | Cause)$$



O numero total de parâmetros é linear em n.

Mundo do Wumpus



- P_{ij} =true sse [i,j] contém um poço
- B_{ij} =true sse [i,j] é ventosa
- Incluir apenas $B_{1,1}$, $B_{1,2}$, $B_{2,1}$ no modelo de probabilidade

Modelo de Probabilidade

A distribuição conjunta total é

$$\mathbf{P}(P_{1,1}, ..., P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1})$$

Aplicando a regra do produto:

•
$$\mathbf{P}(B_{1,1},B_{1,2},B_{2,1} | P_{1,1},...,P_{4,4}) \mathbf{P}(P_{1,1},...,P_{4,4})$$
 (Faz-se assim para obter $\mathbf{P}(Efeito|Causa)$.)

- Primeiro termo: 1 se poços adjacentes a brisa, 0 caso contrario
- Segundo termo: poços são dispostos aleatoriamente, probabilidade de 0.2 por casa:

$$\mathbf{P}(P_{1,1}, ..., P_{4,4}) = \prod_{ij=1,1..4,4} \mathbf{P}(P_{i,j})$$

Para uma configuração com n poços,

$$P(P_{1,1}, ..., P_{4,4}) = 0.2^n \times 0.8^{16-n}$$

Observações e interrogações


Sabemos o seguinte:

$$b = \neg b_{1,1} \wedge b_{1,2} \wedge b_{2,1}$$
$$known = \neg p_{1,1} \wedge \neg p_{1,2} \wedge \neg p_{2,1}$$

- Interrogação é $\mathbf{P}(P_{1.3}|known,b)$
- Seja $Unknown = P_{ij}$ s diferentes de $P_{I,3}$ e Known
- Por inferência por enumeração (marginalização), obtemos $\mathbf{P}(P_{1,3}|known, b) = \alpha \sum_{unknown} \mathbf{P}(P_{1,3}, unknown, known, b)$
- · Cresce exponencialmente com o número de casas!

Utilizando a independência condicional

 Facto fundamental: observações são condicionalmente independentes de outras casas escondidas, dadas as casas escondidas vizinhas




- Definir $Unknown = Fringe \cup Other$ $P(b|P_{1,3},Known, Unknown) = P(b|P_{1,3},Known, Fringe)$
- Manipular interrogação de maneira a que se possa utilizar a igualdade anterior!

Utilizando a independência condicional

$$\begin{split} &\mathbf{P}\big(P_{1,3} \mid known,b\big) = \alpha \sum_{unknown} \mathbf{P}\big(P_{1,3},unknown,known,b\big) \\ &= \alpha \sum_{unknown} \mathbf{P}\big(b \mid P_{1,3},known,unknown\big) \mathbf{P}\big(P_{1,3},known,unknown\big) \\ &= \alpha \sum_{fringe other} \sum_{other} \mathbf{P}\big(b \mid known,P_{1,3},fringe,other\big) \mathbf{P}\big(P_{1,3},known,fringe,other\big) \\ &= \alpha \sum_{fringe other} \sum_{other} \mathbf{P}\big(b \mid known,P_{1,3},fringe\big) \mathbf{P}\big(P_{1,3},known,fringe,other\big) \\ &= \alpha \sum_{fringe} \mathbf{P}\big(b \mid known,P_{1,3},fringe\big) \sum_{other} \mathbf{P}\big(P_{1,3},known,fringe,other\big) \\ &= \alpha \sum_{fringe} \mathbf{P}\big(b \mid known,P_{1,3},fringe\big) \sum_{other} \mathbf{P}\big(P_{1,3}\big) P\big(known\big) P\big(fringe\big) P\big(other\big) \\ &= \alpha P\big(known\big) \mathbf{P}\big(P_{1,3}\big) \sum_{fringe} \mathbf{P}\big(b \mid known,P_{1,3},fringe\big) P\big(fringe\big) \sum_{other} P\big(other\big) \\ &= \alpha' \mathbf{P}\big(P_{1,3}\big) \sum_{fringe} \mathbf{P}\big(b \mid known,P_{1,3},fringe\big) P\big(fringe\big) \end{split}$$

Utilizando a independência condicional



$$\begin{aligned} \mathbf{P} \Big(P_{1,3} \mid known, b \Big) &= \alpha' \Big\langle 0.2 \Big(0.04 + 0.16 + 0.16 \Big), 0.8 \Big(0.04 + 0.16 \Big) \Big\rangle \\ &= \alpha' \Big\langle 0.072, 0.16 \Big\rangle \\ &= \alpha' \Big\langle \frac{0.072}{0.072 + 0.16}, \frac{0.16}{0.072 + 0.16} \Big\rangle \\ &\approx \Big\langle 0.31, 0.69 \Big\rangle \end{aligned}$$

$$\mathbf{P}(P_{2,2} | known, b) \approx \langle 0.86, 0.14 \rangle$$

Casos de Aplicação

Casos de aplicação: Urnas

- Considerem-se duas urnas, a urna A com bolas numeradas de 1 a 10, e a urna B com bolas numeradas de 1 a 1000.
- Escolha-se uma das urnas aleatoriamente
- Retire-se dela uma bola aleatoriamente
- A bola que saiu tem o numero 4,
- Qual a probabilidade da bola ter sido retirada da urna A?

Casos de aplicação: Urnas

Pretendemos obter a probabilidade de:

$$P(Urna = A \mid Bola = 4) = \frac{P(Bola = 4 \mid Urna = A) \times P(Urna = A)}{P(Bola = 4)}$$

$$= \frac{P(Bola = 4 \mid Urna = A) \times P(Urna = A)}{\sum_{u \in \{A,B\}} P(Bola = 4 \land Urna = u)}$$

$$= \frac{P(Bola = 4 \mid Urna = A) \times P(Urna = A)}{\sum_{u \in \{A,B\}} P(Bola = 4 \mid Urna = u) \times P(Urna = u)}$$

$$= \frac{0.1 \times 0.5}{0.1 \times 0.5 + 0.001 \times 0.5} = \frac{0.1}{0.1 + 0.001} \approx 0.99$$

Outra maneira (sem variáveis escondidas):

$$P(Urna = A \mid Bola = 4) = \alpha P(Urna \land Bola = 4) = \alpha P(Urna \mid Bola = 4) \times P(Urna)$$

$$= \alpha \langle 0.1 \times 0.5, 0.001 \times 0.5 \rangle = \alpha \langle 0.05, 0.0005 \rangle$$

$$= \alpha \langle \frac{0.05}{0.05 + 0.0005}, \frac{0.0005}{0.05 + 0.0005} \rangle \approx \langle 0.99, 0.01 \rangle$$

Prólogo:

- Existem 100 cubículos numerados de 1 a 100.
- Os números estão pintados do lado de fora.
- É lançada uma moeda ao ar (não viciada).
- Se sair cara, então uma pessoa é colocada dentro de cada um dos 100 cubículos.
- Se sair coroa, então uma pessoa é colocada dentro de cada um dos dez cubículos.
- Você encontra-se dentro de um dos cubículos.

- Qual é a probabilidade de ter saído cara? 0.5
- Existem 10 ou 100 pessoas nos cubículos? 0.5
- Qual é a probabilidade de estar pintado um número de 1 a 10 no seu cubículo dado que saiu cara? 0.1
- Qual é a probabilidade de estar pintado um número de 1 a 10 no seu cubículo dado que saiu coroa? 1.0
- Suponha que abre a porta e tem o número 7 escrito na porta. Qual é a probabilidade de ter saído coroa? 0.91

- Consideremos agora outra situação "real", com as duas hipóteses rivais:
- A raça humana extinguir-se-á no próximo século, com 200 mil milhões (200×10⁹) o número total de humanos que nasceram.
- 2. A raça humana não se extinguira no próximo século e colonizara a galáxia, sendo o numero total de humanos nascidos 200 biliões (200×10¹²).
- Vamos supor que a probabilidade à priori da hipótese 1 ocorrer é de X%.
- Suponha-se que se sabe que você e o humano numero 60 mil milhões (60×10⁹) (aproximadamente o numero de pessoas que nasceram ate hoje). Qual a probabilidade da raça humana se extinguir no próximo século dada esta informação?

A estocada final:

$$P(Hip = 1 | \text{Você ser a pessoa } 60 \times 10^{9}) =$$

$$= \frac{P(\text{Você ser a pessoa } 60 \times 10^{9} | \text{Hip = 1}) \times P(\text{Hip = 1})}{P(\text{Você ser a pessoa } 60 \times 10^{9})} =$$

$$= \frac{\frac{1}{200 \times 10^{9}} X}{\frac{1}{200 \times 10^{9}} X + \frac{1}{200 \times 10^{12}} (1 - X)} =$$

$$= \frac{X}{X + \frac{1 - X}{1000}} = \frac{1000}{900X + 1}$$

Alguns valores para X:

X	P(Extinção no próximo século você ser a pessoa 60×109
0.1%	50%
1%	90%
2%	95%
5%	98%
10%	99%

 ATENÇÃO: Este argumento é alvo de grande discordância e debate filosófico intenso! Ver e.g. a Wikipédia! (Doomsday Argument)

Casos de aplicação: Monty Hall

- Um apresentador honesto de um programa televisivo colocou um Ferrari atrás de uma de três portas numeradas.
- Existe uma cabra atrás das restantes duas portas.
- Um concorrente não tem qualquer informação que o permita escolher entre qualquer uma das portas.
- O apresentador informa-o das regras do jogo:
 - Primeiro aponte para uma porta. Depois, abrirei uma das outras portas que tem a cabra. Depois de eu lhe mostrar a cabra, terá que tomar a decisão final se mantem a hipótese inicial ou muda para a outra porta. Ganhara aquilo que estiver atrás da porta selecionada no fim.
- Você começa por apontar para a porta numero 1.
- O apresentador abre-lhe a porta 3, que tem uma cabra escondida.
- Qual a sua decisão?

Casos de aplicação: Monty Hall

- Considerem-se as proposições:
- C_i carro encontra-se atrás da porta i∈{1,2,3}.
- A_{ij} o apresentador abre a porta j depois do concorrente escolher a porta i com i,j \in {1,2,3}.
- Vamos determinar P(C₁|A₁₃), recorrendo à Regra de Bayes:
- $P(C_1|A_{13}) = P(C_1 \land A_{13})/P(A_{13}) = P(A_{13}|C_1) \times P(C_1)/P(A_{13})$.
- Para o numerador temos:
- $P(A_{13}|C_1) \times P(C_1) = 1/2 \times 1/3 = 1/6$
- O calculo do denominador é um pouco mais difcil...

Casos de aplicação: Monty Hall

- Para o denomimnador podemos reescrever:
- $P(A_{13}) = \sum_{i \in 1,2,3} P(A_{13}|C_i) \times P(C_i) =$
- = $P(A_{13}|C_1) \times P(C_1) + P(A_{13}|C_2) \times P(C_2) + P(A_{13}|C_3) \times P(C_3)$
- $\bullet = 1/2 \times 1/3 + 1 \times 1/3 + 0 \times 1/3 = 1/2$
- Portanto, $P(C_1|A_{13}) = (1/6)/(1/2) = 1/3$
- Logo, a decisão racional é trocar de porta pois a probabilidade de aí se encontrar o carro é de 2/3.

Sumário

- A teoria das probabilidades é um formalismo rigoroso para lidar com conhecimento incerto
- Distribuição de probabilidade conjunta especifica a probabilidade de todo o acontecimento atómico
- As interrogações podem ser respondidas somando-se acontecimentos atómicos
- Para domínios não triviais, é essencial reduzir o tamanho da distribuição conjunta
- Independência e independência condicional fornecem as ferramentas